

LAPORAN TEKNIS
DATA WRANGLING, PREPROCESSING, DAN
EXPLORATORY DATA ANALYSIS

TripWell
Portal Wisata Inclusive

Tim Data Science
Coding Camp Powered by DBS Foundation
Team Capstone CC26-PSU116

DAFTAR ISI

DAFTAR ISI.....	2
BAB I PROBLEM DISCOVERY	4
1.1 Latar Belakang	4
1.2 Pertanyaan Bisnis	4
BAB II DATA GATHERING	5
2.1 Sumber Data.....	5
2.2 Struktur Dataset	5
BAB III ASSESSING DATA.....	6
3.1 Hasil Pemeriksaan Data	6
3.2 Distribusi Label Sentimen Aksesibilitas.....	6
3.3 Rencana Tindak Lanjut dari Assessing.....	7
BAB IV CLEANING DAN PREPROCESSING DATA.....	8
4.1 Konversi Tipe Data.....	8
4.2 Label Encoding.....	8
4.3 Preprocessing Teks	8
4.3.1 Kamus Normalisasi Slang	9
4.3.2 Justifikasi Tidak Melakukan Stopwords Removal	10
4.4 Output Preprocessing.....	10
BAB V DATA DICTIONARY.....	11
BAB VI EXPLORATORY DATA ANALYSIS	12
6.1 Distribusi Rating.....	12
6.2 Distribusi Panjang Teks	12
6.3 Distribusi Jumlah Ulasan per Lokasi	12
6.4 Analisis Korelasi (Spearman).....	12
6.5 Analisis N-gram.....	12
BAB VII VISUALISASI DAN ANALISIS EXPLANATORY	13
7.1 Pertanyaan Bisnis 1: Proporsi Aksesibilitas Negatif per Lokasi	13
7.2 Pertanyaan Bisnis 2: Kata dan Bigram Diskriminatif (c-TF-IDF)	13
7.2.1 Unigram Diskriminatif	13
7.2.2 Bigram Diskriminatif	14
7.3 Pertanyaan Bisnis 3: Tren Proporsi Aksesibilitas Bulanan.....	14
BAB VIII KESIMPULAN DAN REKOMENDASI	15
8.1 Kesimpulan	15

8.2 Rekomendasi15

BAB I PROBLEM DISCOVERY

1.1 Latar Belakang

Proyek TripWell – Portal Wisata Inklusif yang fokus pada pengembangan sistem yang mampu menyaring dan klasifikasi ulasan wisata berdasarkan aspek aksesibilitas fisik. Sistem ini dirancang untuk membantu *user*, khususnya kelompok dengan kebutuhan mobilitas khusus, dalam memperoleh informasi relevan dan mudah dipahami terkait kelayakan suatu destinasi wisata yang membuat user dapat memutuskan apakah mereka dapat mengunjungi objek wisata tersebut atau perlu pertimbangan tertentu.

1.2 Pertanyaan Bisnis

Penelitian ini menjawab tiga pertanyaan bisnis sebagai berikut:

Tabel 1. Pertanyaan Bisnis Penelitian

No.	Pertanyaan Bisnis
PB 1	Lokasi wisata alam mana di Bandung Barat yang memiliki proporsi ulasan aksesibilitas negatif tertinggi berdasarkan persentase label negatif terhadap total ulasan per lokasi, dan bagaimana rata-rata rating pada lokasi terkait selama periode 2019–2023?
PB 2	Apa saja kata dan bigram paling diskriminatif untuk membedakan ulasan berlabel aksesibilitas positif dan negatif berdasarkan nilai TF-IDF dalam dataset tahun 2019–2023?
PB 3	Bagaimana proporsi bulanan label aksesibilitas negatif, netral, dan positif berubah sepanjang 2019–2023, dan apakah terdapat tren atau pola musiman?

BAB II DATA GATHERING

2.1 Sumber Data

Dataset yang digunakan adalah ABSA Natural Tourist Attractions Review yang tersedia secara publik di platform Kaggle. Dataset ini berisi ulasan berbahasa Indonesia dari pengunjung destinasi wisata alam di Bandung Barat, dilengkapi dengan label sentimen aspek-based untuk tiga dimensi: aksesibilitas, fasilitas, dan aktivitas.

2.2 Struktur Dataset

Tabel 2. Informasi Dataset

Atribut	Keterangan
Sumber	Kaggle — ABSA Natural Tourist Attractions Review
Format	CSV (tourist_reviews.csv)
Jumlah Baris	11.620 ulasan
Kolom Utama	id, datetime, location, rating, text, accessibility, facility, activity
Periode	Februari 2019 – Februari 2023

BAB III ASSESSING DATA

3.1 Hasil Pemeriksaan Data

Tahap asesmen bertujuan memahami kualitas dan karakteristik data sebelum dilakukan transformasi. Beberapa aspek yang diperiksa meliputi tipe data, distribusi label, duplikasi, missing value, dan karakteristik teks.

Tabel 3. Hasil Pemeriksaan Kualitas Data

Aspek yang Diperiksa	Temuan
Missing Value	Tidak ditemukan missing value pada semua kolom
Duplikasi Struktural	Tidak ditemukan baris duplikat secara struktural
Tipe data datetime	Bertipe object, perlu dikonversi ke datetime
Label kategorik	Tipe string (negative/neutral/positive), perlu di-encode
Kolom text	Mengandung slang, emoji, HTML tag, dan URL — perlu preprocessing
Distribusi label accessibility	Negative: 862 Neutral: 10.197 Positive: 561
Jumlah kata unik (max_words)	Dihitung dari seluruh teks kolom text (semua label)
Panjang teks maks. (max_length)	Dihitung dari kolom word_count yang dibuat saat assessing

3.2 Distribusi Label Sentimen Aksesibilitas

Tabel 4. Distribusi Label Sentimen Aksesibilitas

Label	Jumlah	Persentase (%)
negative (0)	862	7,4%
neutral (1)	10.197	87,8%
positive (2)	561	4,8%
Total	11.620	100%

Ketidakseimbangan kelas (imbalanced classes) yang sangat besar menjadi perhatian utama. Label neutral mendominasi dengan 87,8%, sehingga augmentasi data diperlukan saat modelling.

3.3 Rencana Tindak Lanjut dari Assessing

Berdasarkan hasil asesmen, rencana tindak lanjut yang ditetapkan adalah:

- Konversi tipe data kolom datetime dari object ke datetime.
- Label Encoding pada fitur kategorik dengan urutan ordinal.
- Preprocessing teks pada kolom text untuk menghilangkan noise.
- Stopwords removal tidak dilakukan karena kata seperti 'tidak', 'belum', 'kurang' krusial untuk klasifikasi sentimen.
- Augmentasi data dengan sinonim swap pada data train saat modelling.

BAB IV CLEANING DAN PREPROCESSING DATA

4.1 Konversi Tipe Data

Kolom datetime awalnya bertipe object (string). Dikonversi ke tipe datetime64 menggunakan pandas agar operasi berbasis waktu dapat dilakukan dengan benar, termasuk groupby bulanan dan analisis tren temporal.

```
df["datetime"] = pd.to_datetime(df["datetime"])
```

4.2 Label Encoding

Kolom accessibility, facility, dan activity diubah dari tipe string menjadi integer menggunakan mapping ordinal. Urutan ordinal dipilih karena ketiga label memiliki makna bertingkat: negatif < netral < positif.

Tabel 5. Mapping Label Encoding

Label Asli	Nilai Encoded	Makna
negative	0	Sentimen negatif
neutral	1	Sentimen netral
positive	2	Sentimen positif

4.3 Preprocessing Teks

Preprocessing teks dilakukan melalui fungsi clean_text() yang diaplikasikan ke kolom text, menghasilkan kolom baru text_clean. Fungsi ini terdiri dari delapan langkah berurutan.

Tabel 6. Langkah-langkah Preprocessing Teks

No.	Langkah	Keterangan
1	Lowercase	Seluruh teks diubah ke huruf kecil
2	Hapus HTML Tags	Menggunakan BeautifulSoup untuk strip tag HTML
3	Hapus URL	Regex menghapus http, www, https
4	Angka + Satuan	Angka dengan satuan (km, meter, menit) disimpan; angka murni dihapus
5	Hapus Emoji/Non-Latin	Hanya karakter a-z, 0-9, dan spasi yang dipertahankan
6	Normalisasi Spasi	Spasi ganda, tab, newline dihapus
7	Normalisasi Slang	Kata gaul/singkatan diubah ke bentuk formal
8	Filter Teks Pendek	Teks dengan kurang dari 2 kata setelah cleaning di-set None

4.3.1 Kamus Normalisasi Slang

Sebanyak 37 entri slang/singkatan bahasa Indonesia didefinisikan secara eksplisit dalam kamus slang_dict. Tabel 7 menampilkan seluruh entri normalisasi yang digunakan.

Tabel 7. Kamus Normalisasi Slang Lengkap

Slang / Singkatan	Hasil Normalisasi
gk, ga, gak, nggak, tdk	tidak
bgt, bngt	banget
bnr	benar
sy, gw, gue	saya
dr	dari
mntap, mantul	mantap
yg	yang
utk	untuk
jd	jadi
jg	juga
jln	jalan
krn	karena
dgn	dengan
blm	belum
sdh	sudah
msh	masih
aja	saja
emang	memang
trs	terus
dpt	dapat
sm	sama
kmrn	kemarin
tp	tapi
klo, kl	kalau
udh, udah	sudah
bs	bisa

Slang / Singkatan	Hasil Normalisasi
byk	banyak
lg	lagi
lbh	lebih

4.3.2 Justifikasi Tidak Melakukan Stopwords Removal

Stopwords removal secara sengaja tidak dilakukan. Kata-kata yang umumnya masuk daftar stopwords bahasa Indonesia seperti ‘tidak’, ‘belum’, ‘kurang’, ‘sangat’, dan ‘terlalu’ justru merupakan kata-kata paling penting dalam menentukan polaritas sentimen. Menghapusnya akan secara signifikan menurunkan kemampuan model membedakan ulasan positif dan negatif.

4.4 Output Preprocessing

Hasil akhir preprocessing adalah:

- Kolom baru text_clean ditambahkan ke dataframe.
- Teks yang terlalu pendek setelah cleaning di-set None (nilai null).
- Seluruh hasil disimpan ke file preprocessed_dataset.csv.
- File ini digunakan sebagai input untuk EDA dan modelling.
- Label neutral pada fitur accessibility tidak digunakan saat modelling karena tidak bermakna, namun tetap disimpan di preprocessed_dataset.csv untuk keperluan EDA dan dashboard

BAB V DATA DICTIONARY

Data dictionary dibuat secara otomatis dari file `preprocessed_dataset.csv` dan disimpan sebagai `data_dictionary.json`. Dictionary ini mendokumentasikan nama kolom, tipe data, statistik deskriptif, dan metadata preprocessing.

Tabel 8. Data Dictionary Dataset Preprocessed

Kolom	Tipe Data	Deskripsi	Preprocessing
id	object	Identifikasi unik tiap ulasan	-
datetime	object	Tanggal dan waktu ulasan diberikan	-
location	object	Nama destinasi wisata alam	-
text	object	Teks ulasan asli dari pengunjung	-
rating	int64	Rating bintang 1–5 dari pengunjung	-
accessibility	int64	Label sentimen aksesibilitas	Label Encoding (0/1/2)
facility	int64	Label sentimen fasilitas	Label Encoding (0/1/2)
activity	int64	Label sentimen aktivitas	Label Encoding (0/1/2)
word_count	int64	Jumlah kata pada teks ulasan asli	Dihitung dari kolom text
text_clean	object	Teks ulasan setelah preprocessing	Cleaning + Slang Norm.

BAB VI EXPLORATORY DATA ANALYSIS

EDA dilakukan pada file `preprocessed_dataset.csv` yang telah dilakukan preprocessing untuk memahami karakteristik data secara mendalam sebelum menjawab pertanyaan bisnis.

6.1 Distribusi Rating

Mayoritas pengunjung (7.636 dari 11.620 ulasan) memberikan rating 5 dengan rata-rata rating keseluruhan sebesar 4,50. Distribusi bersifat sangat left-skewed yang menunjukkan kepuasan pengunjung yang tinggi secara umum.

6.2 Distribusi Panjang Teks

Analisis dilakukan khusus pada ulasan dengan label aksesibilitas non-netral. Panjang teks maksimum absolut adalah 337 kata per ulasan. Nilai P90 berada di sekitar 98 kata, P95 di sekitar 131 kata, dan P99 di sekitar 22 kata. Nilai P95 (131 kata) direkomendasikan sebagai `max_length` model BiLSTM berdasarkan keseimbangan antara kelengkapan informasi dan efisiensi komputasi.

6.3 Distribusi Jumlah Ulasan per Lokasi

Distribusi ulasan sangat tidak merata antar lokasi. Sarae Hills memiliki ulasan terbanyak (952 ulasan), sementara Sirtwo Island Saguling hanya memiliki 3 ulasan. Ketidakmerataan ini perlu diperhatikan dalam interpretasi hasil, terutama untuk lokasi dengan sampel sangat kecil.

6.4 Analisis Korelasi (Spearman)

Spearman correlation digunakan karena fitur bersifat ordinal. Korelasi antar semua fitur berkisar antara 0,02 hingga 0,16, menunjukkan tidak adanya multikolinearitas signifikan. Setiap fitur relatif independen sehingga masing-masing label dapat dimodelkan secara terpisah.

6.5 Analisis N-gram

Bigram dan trigram yang paling sering muncul didominasi frasa umum deskriptif seperti 'tempat yang' dan 'tempat wisata yang' yang tidak bersifat diskriminatif. Temuan ini memotivasi penggunaan pendekatan c-TF-IDF pada analisis Pertanyaan Bisnis 2.

BAB VII VISUALISASI DAN ANALISIS EXPLANATORY

7.1 Pertanyaan Bisnis 1: Proporsi Aksesibilitas Negatif per Lokasi

Analisis dilakukan dengan menghitung proporsi label aksesibilitas per lokasi menggunakan agregasi groupby dua level untuk mengidentifikasi lima lokasi dengan persentase label negatif tertinggi.

Tabel 9. Top 5 Lokasi dengan Proporsi Aksesibilitas Negatif Tertinggi

Lokasi	% Negatif	% Netral	% Positif	Avg. Rating
Curug Malela	52,5%	45,5%	2,0%	4,49
Bukit Senyum	18,8%	77,5%	3,7%	4,39
Curug Layung Camp Situ Lembang	17,2%	79,3%	3,5%	4,56
Stone Garden	16,8%	80,0%	3,2%	4,48
Sanghyang Heuleut	16,2%	79,1%	4,7%	4,53

Curug Malela menjadi outlier yang mencolok sebagai satu-satunya lokasi dengan sentimen negatif lebih dari 50% (52,5%), hampir tiga kali lipat lokasi kedua. Empat lokasi lainnya memiliki pola seragam dengan label netral mendominasi (77–80%). Terdapat konsistensi antara aksesibilitas negatif yang tinggi dengan rata-rata rating yang lebih rendah.

7.2 Pertanyaan Bisnis 2: Kata dan Bigram Diskriminatif (c-TF-IDF)

Pendekatan c-TF-IDF (Cluster-level TF-IDF) dari metodologi BERTopic digunakan untuk mengidentifikasi kata dan bigram yang paling eksklusif per kelas. Berbeda dengan TF-IDF standar, c-TF-IDF menggabungkan semua teks dalam satu kelas menjadi satu megadokumen sehingga kata eksklusif pada suatu kelas mendapat bobot tinggi.

Sebelum komputasi c-TF-IDF, diterapkan custom stopwords yang membedakan antara kata penghubung netral yang dihapus (yang, dan, di, untuk, nya, juga, ke, dari, ada, dengan, ini, itu) dan kata kunci sentimen yang dipertahankan (tidak, kurang, belum, terlalu, sangat, bagus, mudah, jalan, akses). Pendekatan ini memastikan kata-kata bermuatan sentimen tidak ikut terhapus.

7.2.1 Unigram Diskriminatif

Tabel 10. Unigram Diskriminatif per Kelas Sentimen

Rank	Unigram Kelas Negatif	Unigram Kelas Positif
1	jalan	sangat
2	tidak	bisa
3	akses	parkir
4	diperbaiki	tiket

Rank	Unigram Kelas Negatif	Unigram Kelas Positif
5	masih	mudah

7.2.2 Bigram Diskriminatif

Tabel 11. Bigram Diskriminatif per Kelas Sentimen

Rank	Bigram Kelas Negatif	Bigram Kelas Positif
1	kurang bagus	sangat mudah
2	sayang jalan	lokasi mudah
3	masih jelek	akses jalan (positif)
4	rusak parah	tidak terlalu jauh
5	saat hujan	kawah ratu / tangkuban perahu

Unigram negatif didominasi kata terkait kondisi jalan yang buruk ('jalan', 'tidak', 'diperbaiki'), sementara unigram positif mencerminkan kemudahan akses ('sangat', 'parkir', 'mudah'). Bigram memberikan informasi lebih spesifik: kelas negatif ditandai 'kurang bagus' dan 'rusak parah', sedangkan kelas positif ditandai 'sangat mudah' dan 'lokasi mudah'. Kemunculan nama lokasi spesifik seperti 'kawah ratu' dan 'tangkuban perahu' pada bigram kelas positif mengindikasikan bahwa lokasi-lokasi tersebut secara khusus mendapat penilaian aksesibilitas positif dari pengunjung. Selain itu, frasa 'tiket masuk' muncul di kedua kelas, yang berarti aspek tiket dibicarakan baik oleh pengunjung yang puas maupun kecewa — kemungkinan dianggap sebanding oleh yang puas, namun tidak worth it bagi yang kecewa dengan aksesibilitasnya.

7.3 Pertanyaan Bisnis 3: Tren Proporsi Aksesibilitas Bulanan

Analisis temporal dilakukan dengan mengagregasi data per bulan menggunakan `dt.to_period('M')` untuk menghitung proporsi label aksesibilitas setiap bulan sepanjang 2019–2023.

Rating bulanan bersifat sangat stabil di rentang 4,35–4,65 tanpa tren naik atau turun yang signifikan sepanjang periode. Fluktuasi yang sedikit lebih terlihat pada 2022–2023 disebabkan oleh volume ulasan yang jauh lebih kecil, sehingga setiap ulasan memiliki bobot proporsional yang lebih besar terhadap rata-rata.

Volume ulasan menunjukkan tren penurunan bertahap dari awal 2019 (sekitar 2.500 ulasan per bulan) hingga awal 2022 (sekitar 1.850 ulasan per bulan), diikuti drop drastis di pertengahan 2022 menjadi sekitar 200 ulasan per bulan. Penurunan signifikan ini kemungkinan besar merupakan dampak penutupan atau pembatasan wisata pasca-pandemi COVID-19.

Pada proporsi label aksesibilitas, label netral mendominasi secara konsisten di atas 75% sepanjang seluruh periode. Tidak ditemukan tren naik/turun yang konsisten maupun pola musiman yang jelas pada label negatif maupun positif.

BAB VIII KESIMPULAN DAN REKOMENDASI

8.1 Kesimpulan

Berdasarkan seluruh tahapan analisis yang telah dilakukan, dapat ditarik beberapa kesimpulan berikut:

- Proses data wrangling dan preprocessing berhasil menghasilkan dataset bersih yang siap untuk analisis lanjutan. Normalisasi slang meningkatkan kualitas fitur teks tanpa kehilangan sinyal sentimen.
- Curug Malela adalah satu-satunya destinasi dengan aksesibilitas negatif dominan (52,5%), menjadikannya prioritas utama untuk perbaikan infrastruktur aksesibilitas.
- Kondisi jalan, terutama saat musim hujan, adalah isu utama ulasan negatif. Bigram c-TF-IDF sangat potensial sebagai fitur klasifikasi sentimen aksesibilitas.
- Rating wisata konsisten tinggi sepanjang 2019–2023 tanpa pola musiman yang signifikan. Penurunan volume ulasan di 2022 mencerminkan dampak pandemi COVID-19.

8.2 Rekomendasi

Berdasarkan hasil analisis, rekomendasi untuk tahap selanjutnya adalah:

- **Augmentasi Data:** Terapkan synonym swap hanya pada data train untuk mengatasi ketidakseimbangan kelas.
- **Exclude Label Neutral:** Fokuskan klasifikasi biner (positif vs negatif) karena label netral tidak bermakna untuk prediksi.
- **Max Length Model:** Gunakan P95 (131 kata) sebagai max_length untuk model BiLSTM.
- **Fitur Bigram:** Integrasikan bigram dari c-TF-IDF sebagai fitur tambahan dalam model klasifikasi.
- **Perhatian Khusus Curug Malela:** Lakukan investigasi lebih lanjut terhadap ulasan negatif di lokasi ini untuk mengidentifikasi akar masalah aksesibilitas.